

氣候災害經濟衝擊分析

Global Climate Events & Economic Impact Analysis

課程 CE5033 · 第 7 組

資料探勘與機器學習 | 2020–2025 全球氣候事件資料集

組員：劉庭瑋 張皓軒 李知祐

研究動機與核心問題

- ▶ 近年全球極端氣候事件頻傳，經濟損失動輒數十億美元，成為各國高度關注的議題
- ▶ 關鍵問題：決定災損的，是災害本身的物理強度，還是受災地區的人文條件？
 - **RQ1（關聯）**：哪些因素與經濟損失相關？線性直覺是否可靠？
 - **RQ2（推論）**：高嚴重度是否「顯著且實質」造成更高損失？
 - **RQ3（預測）**：當經濟損失未知時，能否以其他特徵預測巨災？
- ▶ 方法論立場：同時檢視統計顯著性、效應量與非線性模型，並誠實揭露限制

資料集介紹 Dataset


- ▶ 來源：Kaggle — Global Climate Events & Economic Impact Dataset (2020–2025)
- ▶ 規模：3,000 筆事件 × 20 個欄位，51 國、12 種災害類型
 - 變數型態：數值型 (severity, duration_days, affected_population, impact_per_capita...)
 - 類別型 (country, event_type)
- ▶ Target：economic_impact_million_usd (經濟損失，百萬美元)
- ▶ 資料品質：原始資料無缺失值 (0 missing)

敘述統計與資料輪廓

Feature	Mean	Std	Median	Max	Skewness
severity	3.79	2.01	4	9	0.29
duration_days	8.78	14.71	2	115	2.94
affected_population	868,550	3,009,690	178,477	56,248,325	9.37
deaths	4.62	11.02	2	117	4.82
economic_impact	1.94	15.73	0.09	718.21	34.01
infra_damage_score	15.16	11.50	12.40	63	1.15
impact_per_capita	3.61	10.78	0.48	181.62	7.11

► Key Findings

- **economic_impact** : skewness 34, Median: 0.09M << Mean: 1.94M
- affected_population (9.4)、impact_per_capita (7.1)、deaths (4.8)
- **Severity** 近乎對稱 (0.29)：分布均勻，損失卻極端 → 形狀不匹配，可能損失非單由強度決定
- Affected_population 從 622 到 5,625 萬



Step 1 | Data Preprocessing

- ▶ 缺失值處理：本資料無缺失
- ▶ Z-score 標準化：消除欄位間的單位與尺度差異
- ▶ 產出兩份資料：
 - processed：保留原始單位（百萬美元），供解讀與統計檢定
 - standardized：標準化後資料，供相關分析與距離型演算法
- ▶ 工程實作：儲存於 `src/cleaning.py`，notebook 僅呼叫 `clean_data()`

前處理方法原理

- ▶ **Z-score 標準化公式**： $z = (x - \mu) / \sigma$ → 轉為平均 0、標準差 1
 - 使各特徵同尺度，避免大數值特徵主導相關係數與距離計算
- ▶ **標準化不改變分布形狀與相關係數**：故統計檢定（需原始單位解讀）用 **processed**，相關分析用 **standardized**

MYTH 1

「災害持續越久，受災人口就越多」？

聽起來理所當然——時間拉長，影響範圍應該越廣。

我們用相關性、分佈與迴歸三種角度交叉檢驗。


迷思一驗證 | 相關性熱力圖

▶ **duration ↔ affected : $r \approx 0.01$** (近乎零相關)

▶ 與經濟損失的線性相關 (Pearson r) :

- aid_percentage 0.84 · intl_aid 0.84
- 但災後援助(aid)是損失發生之後才有的，非原因 → 建模須剔除 (data leakage)
- impact_per_capita 0.32 · affected 0.22
- duration 0.17 · severity 0.12 (皆偏低)

▶ 事前factors 的『線性』關係普遍不強



迷思一驗證 | 分佈、長尾與極端值


▶ 兩變數皆右偏長尾 ▶ (skewness, 常態 = 0) :

- affected_population : 偏度 9.4、峰度 114

- duration_days : 偏度 2.9、峰度 10.3

- 高峰度 = 厚尾，極端事件遠比常態頻繁

▶ 長尾與離群值正是線性方法失效、需非線性模型的原因



迷思一結論 | 散佈圖與小結

▶ 散佈圖 + OLS 迴歸線：紅線近乎水平


- 資料點無明顯趨勢，無線性關係

▶ 小結：直覺 $\neq$ 數據

• 「持續越久→受災越多」的線性直覺被推翻

▶ 重要但常被忽略：低『線性』相關 $\neq$ 無關

• Pearson r 只衡量線性；非線性關係它看不見



迷思二 | 高嚴重度 = 高經濟損失？

▶ 研究假設：

- H_0 ：高/低嚴重度兩組的平均經濟損失相同
- H_1 ：高嚴重度組平均損失較高（單尾 one-tailed）

▶ 分組（依 severity 平均切）：高 $n=1,573$ 、低 $n=1,427$

▶ 兩組標準差差異懸殊：**21.5 vs 2.7**

- → 違反變異數同質假設，故採 Welch's t-test（不假設變異數相等）

統計檢定方法細節 Test Details

▶ **Cohen's d 公式**： $d = (\bar{x}_1 - \bar{x}_2) / s_p$ ， s_p 為合併標準差

- 效應量分級： $|d| \approx 0.2$ 小、0.5 中、0.8 大

▶ **檢定統計量與自由度**：

- $t = 5.44$ ，Welch 自由度 $df \approx 1627$

▶ **前提假設與檢核**：

- 獨立性（兩組為不同事件）✓；大樣本下依中央極限定理近似常態（惟資料右偏，為一限制）
- Welch 放寬變異數同質要求，較 Student's t 穩健

迷思二結論 | 統計顯著 $\neq$ 實質重要

p-value (顯著性)

3.02e-08

遠小於 0.05 $\rightarrow$ 統計上顯著

Cohen's d (效應量)

0.19

$< 0.2 \rightarrow$ 效應極小 small

- ▶ reject H_0 : 高嚴重度組平均損失高出 2.97M , 95% CI [1.9, 4.0] (不含 0)
- ▶ 但 Cohen's d $\approx 0.19 \rightarrow$ 兩組差異的『實質效應』其實很小
- ▶ 關鍵啟示 : **statistically significant $\neq$ practically important**
- ▶ 大樣本 (n=3000) 下 , 再小的差異也容易顯著 $\rightarrow$ 必須同時報告效應量與信賴區間

線性方法「看不到」的關係 非線性模型「抓得到」

Pearson r 、 t 檢定皆建立在線性與分布假設上。但真實災損常是非線性、有交互作用、跨越臨界點才爆發
因此改用 Random Forest，重新檢視哪些因子真正驅動巨大災損。

為何選 Random Forest ?

▶ Random Forest = 多棵決策樹的集成 (bagging) 投票

- 能捕捉非線性與特徵交互作用（單一線性模型做不到）
- 對離群值與長尾分布穩健，無需常態假設
- 可直接輸出特徵重要性，利於解釋

▶ 類別不平衡問題：巨災僅 604 筆 vs 一般 2,396 筆（約 20% : 80%）

- → 用 stratified split 分層抽樣保持比例
- → **Accuracy** 易被多數類灌水，故同時看 **F1**、**Recall**、混淆矩陣

Step 4 : Modeling Setup

- ▶ 問題定義：經濟損失前 20% (≥ 0.84 M) 標記為「巨災 (1)」，其餘為「一般 (0)」
- ▶ 特徵工程：類別變數以 one-hot (get_dummies) 編碼 → 共 73 個特徵
- ▶ 資料洩漏防範（關鍵）：剔除與損失同源/事後的欄位
 - economic_impact 自身、injuries、international_aid、aid_percentage（與損失高度耦合）
- ▶ 超參數：RandomForestClassifier(n_estimators=100, random_state=42)
- ▶ 資料切分：訓練 2,400 / 測試 600 (8:2，stratified 分層)

模型評估 | 交叉驗證與穩健性


▶ 5-fold Stratified Cross-Validation（避免單次切分的運氣成分）：

- **Accuracy = 94.4% ± 0.8%**
- **F1 (巨災類) = 84.4% ± 2.4%**
- 標準差極小 → 模型穩定，無明顯過擬合

▶ 對照基準 (baseline)：

- 全猜「一般災害」的多數類基準 = 79.9%
- **模型 94.4% 顯著優於基準 → 確實學到有效資訊**

模型評估 | 混淆矩陣與雙類別指標



類別	Precision	Recall	F1
一般 (0)	0.94	0.99	0.96
巨災 (1)	0.95	0.73	0.82
Macro avg	—	—	0.89

- 巨災精準度高 (0.95)：預測為巨災時多半正確
- 但Recall僅 0.73：漏抓 33/121 真實巨災 (False Negative)
- 防災情境下漏報代價高 → 未來可調整決策閾值或 class_weight 提升 recall


結果 | Top 10 特徵重要性

► Gini importance：特徵在所有樹中平均降低的不純度

- 1. **impact_per_capita (24.6%)**
- 2. **affected_population (15.2%)**
- 3. **duration_days (14.2%)**
- 5. severity 物理嚴重度 (僅 4.3%)

► Gini importance 對高基數變數有偏誤

→ 未來可用 permutation importance / SHAP 交叉驗證



綜合洞見 Key Insights

▶ ① 人本指標 > 物理指標

- 決定巨災的是 impact_per_capita 與 affected_population，而非 severity（排第五）。破壞力取決於『發生在哪、影響多少人』。

▶ ② duration 線性看不到、非線性抓得到（呼應迷思一）

- 線性相關僅 $r \approx 0.01$ ，但 RF 給它約 14% 重要性 → 非線性效應（可能存在臨界天數）

▶ ③ 災害類型差異：緩發型損失更高

- 平均經濟損失最高：Heatwave 9.2M、Drought 5.1M、Cold Wave 5.1M

研究限制與客觀討論 Limitations

- ▶ 資料面：單一公開資料集（可能為合成資料），外推真實世界需謹慎；僅涵蓋 2020–2025
- ▶ 標籤面：「巨災」以 80 百分位人為定義，閾值選擇會影響類別分布與結論
- ▶ 統計面：t 檢定依大樣本近似常態，但資料極度右偏；Pearson r 僅捕捉線性關係
- ▶ 模型面：未做超參數調校；Gini importance 有偏誤；巨災 recall 偏低 (0.73)
- ▶ 因果面：所有發現皆為『關聯』而非『因果』，不可據此直接推論政策因果

Conclusion & References

► 推翻直覺迷思

- 「持續越久→受災越多」被線性分析推翻 ($r \approx 0.01$)
- 「高嚴重度→高損失」統計顯著，但效應量 ($d=0.19$) 顯示實質影響小
- 非線性 **RF** 揭露：人本指標主導，**duration** 確有（非線性）重要性

► 方法論：相關係數/p 值各有盲點，應併用效應量、信賴區間與非線性模型交叉驗證

► 資料集 **Dataset**

- Global Climate Events & Economic Impact Dataset (2020–2025). Kaggle, author: uom190346a.
- kaggle.com/datasets/uom190346a/global-climate-events-and-economic-impact-dataset

► 軟體與套件 **Software & Libraries**

- Python 3 | pandas, NumPy, SciPy, scikit-learn, matplotlib, seaborn

► 方法文獻 **Methods**

- Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.
- Welch, B. L. (1947). The generalization of 'Student's' problem. Biometrika, 34(1/2).
- Cohen, J. (1988). Statistical Power Analysis for the Behavioral Sciences (2nd ed.).

Thanks for your attention

